Аудит идей по чанкингу и Hybrid Search: «Навигатор по регламентам МФТИ»

Сравнительная оценка материалов `ответ_соннет.txt` (Д1) и `Чанкинг и Hybrid Search - анализ (2).docx` (Д2) на основе верификации корпуса из 20 файлов и критериев оценки ТЗ

1. Привязка к ТЗ и верифицированной структуре датасета

Архитектура парсинга, чанкинга и поиска напрямую определяет **52 из 100 технических баллов** жюри: **К1 (20 б.)** — извлечение структуры вплоть до пунктов/подпунктов (8 б.), привязка фрагментов к документу/разделу/пункту (6 б.), масштабируемость без ручной правки кода (5 б.); **К2 (10 б.)** — учёт дат/версий (4 б.) и точное указание редакции и пункта (6 б.); **К3 (22 б.)** — релевантность поиска (6 б.), полнота извлечения шагов процедуры (8 б.), учёт ролей и условий (5 б.); дополнительно в **К4 (20 б.)** — явный показ противоречий между документами (3 б.) и отказ при отсутствии ответа в базе (5 б.).

Фактическая ревизия папки `данные/` (20 файлов: 9 PDF на 79 стр., 8 DOCX, 3 XLSX):

- **Сканы без текстового слоя — 5 из 9 PDF (44 из 79 стр.):** `460-1 Открытие ФЛС.pdf` (19 стр., рукописный № от 28.04.2017), `Регламент бронирования конц зала.pdf` (14 стр., штамп № 3897-1 от 01.09.2025), `Приказ и регламент по ЭБ.pdf` (6 стр., № 1027-1 от 25.06.2019, *таблицы на стр. 5–6 повернуты на 90°*), `Регламент эксплуатации ЦОД.pdf` (5 стр., № 1292-1 от 28.03.2025), `Регламент поселения сотрудников.pdf` (3 стр., 2024 г.; *дефект исходного скана: стр. 1 обрывается на заголовке Раздела 2, а стр. 2 начинается сразу с п. 2.6 — пункты 2.1–2.5 физически отсутствуют*).
- **Версионные цепочки и коллизии:** (1) **ФЛС:** приказ `460-1` (2017, бумажный обход через ПФО) → приказ `3065-1` (25.11.2021, изменяет `1385-1` от 2020, переводит открытие ФЛС в `1С:ДО` и вводит учёт РИД) + распоряжение `700` (28.12.2024, 15-значная структура кода ФЛС). (2) **Сметы:** приказы `794-1` (28.03.2023) и `889-1` (04.04.2023) + бланки 2023 г. (`Приложение 1а/1б`) против старой формы 2019 г. (`Приложение 1_новая смета 2019.xlsx`). (3) **Суточные:** приказ `3699-1` (18.08.2025, п. 17: 100 руб. работникам, 50 руб. обучающимся) против проекта `Регламент о командировании.pdf` (2025, без номера: «не более 100 руб.»). (4) **Заимствования:** приказ `5990-1` (03.11.2026) отменяет приказ `1465-1` (2020).
- **Аномалии вёрстки:** в 8 DOCX нет автонумерации `w:numPr` (все номера — обычный текст) и сломаны стили `Heading`; внутри одного файла до 6 независимых единиц (`Приказ` + `Приложения 1..N`) со сбросом нумерации с `1.`; в `Приказ N 3065-1` дублируются номера пунктов `2.6` и `2.7`; в DOCX лежат огромные таблицы `ЛИСТ СОГЛАСОВАНИЯ`.

2. Сводная матрица оценки предложенных идей

Полезные и дорабатываемые идеи	Ист.	Вердикт	Краткое обоснование относительно проекта
Дерево `file` → `unit` → `section` → `clause` → `item` + **V3 (Parent-Child)**	Д1, Д2	**[В ЯДРО]**	Закрывает К1 (14 б.) и К3 (8 б.): индекс по `clause` ($\leq$ 1200 симв.) даёт точный пункт, подтягивание `section` даёт полный алгоритм шагов.
Разделение синтетического `chunk_id` и отображаемого `clause_no`	Д1, Д2	**[В ЯДРО]**	Критично из-за сброса нумерации в приложениях и дублей номеров пунктов (`2.6`, `2.7` в `3065-1`) внутри одного файла.
Детерминированный префикс (*хлебные крошки*) в `embed_text`	Д1, Д2	**[В ЯДРО]**	Без префикса `[Приказ · Приложение · Раздел]` короткие пункты («2.3. Срок — 3 р.д.») теряют смысл при векторизации.
Сегментация зон и исключение `ЛИСТ СОГЛАСОВАНИЯ` из поиска	Д1, Д2	**[В ЯДРО]**	Таблицы согласования 1С:ДО содержат десятки ФИО и должностей, замусоривая выдачу по ролевым запросам (К3).
Лемматизированный BM25 (`pymorphy3`) + глоссарий + Dense (`BGE-M3`) + `exact=True`	Д2 (Д1)	**[В ЯДРО]**	На $\sim$800 чанках полный перебор `exact=True` в Qdrant занимает < 5 мс; лемматизация и расшифровка (`ФЛС`, `КФО`, `ЦФО`) обязательны для русского языка.
Парсинг DOCX через `iterchildren()` + дедупликация слитых ячеек	Д2	**[В ЯДРО]**	Стандартный обход `doc.paragraphs` теряет позицию таблиц внутри пунктов, а объединённые ячейки дублируют текст в `python-docx`.
Forward-fill иерархии в XLSX + чанки по 10–15 строк с шапкой + формулы смет	Д1, Д2	**[В ЯДРО]**	В `Фин. структуре 2026` (525 строк) родительские ЦФО указаны только в верхней ячейке группы; в сметах 2019/2023 правила зашиты в формулах (`0.082`, `0.2`).
Калиброванный порог реранкера для детекции «ответа нет в базе»	Д1, Д2	**[В ЯДРО]**	Прямое требование К4 (5 б.): отказ должен срабатывать до генерации или через строгий флаг при `max_rerank_score` $< \tau$.
Чек-лист приёмки парсера + золотой датасет на 50 вопросов	Д2	**[В ЯДРО]**	Единственный способ гарантировать отсутствие тихих потерь пунктов и регрессий перед защитой.
Реестр версий (`supersedes`, `status`) + YAML-оверрайд метаданных	Д1, Д2	**[ДОРАБОТАТЬ]**	Вести граф версий обязательно, но YAML должен быть *кэшем/оверрайдом поверх автоэкстрактора*, чтобы не нарушить К1 (5 б. за новые файлы без правки кода).
Фильтрация `status != superseded` в Qdrant по умолчанию	Д1, Д2	**[ДОРАБОТАТЬ]**	**Нельзя резать жёстким фильтром!** Иначе система потеряет 5 приложений базового приказа `460-1` и не сможет показать противоречия редакций (К2, К4). Нужен мягкий бустинг + парная подгрузка версий.
Дедупликация парных файлов (`3614-1` и `3699-1`)	Д1, Д2	**[ДОРАБОТАТЬ]**	`sha256(file)` из Д1 не сработает (разные форматы DOCX и XLSX, разный состав). Дедуплицировать нужно на уровне `unit`/таблицы с сохранением обоих `doc_id`.

Отклоняемые идеи и ошибки	Ист.	Вердикт	Причина отказа / почему вредит проекту
Тезис об отсутствии 3 регламентов (поселение, подбор, ЦОД) и всего 3 сканах	Д1	[ОТКЛОНИТЬ]	**Фактическая ошибка Д1:** все 20 файлов есть в папке `данные/`, а сканов 5, а не 3. Отказ отвечать по этим темам обнулит баллы на базовых вопросах.
Ставка на голый `Tesseract OCR` как основной движок для сканов	Д1, Д2	[ОТКЛОНИТЬ]	В системе нет `rus.traineddata`; Tesseract даёт битые слова, не читает рукописные номера приказов (`460-1`, `1027-1`) и ломается на повёрнутых на 90° таблицах ЭБ. Нужен VLM-OCR с кэшированием по хэшу.
Двухэтапный поиск: сначала Top-K по «карточке документа», затем поиск пунктов	Д1	[ОТКЛОНИТЬ]	На корпусе в 800 чанков это искусственное бутылочное горлышко: ошибка на 1-м шаге убивает полноту в мультидокументных вопросах (`3699-1` + `Командировки`).
LLM Contextual Retrieval (**V4**: 800 вызовов LLM при индексации) и **HyDE**	Д1, Д2	[ОТКЛОНИТЬ]	Детерминированный шаблон хлебных крошек даёт 95% эффекта бесплатно; 800 вызовов LLM при старте Docker-контейнера замедлят развёртывание (риск по К6 — 20 б.).
Fixed-window (**V0**), разрез только по разделам (**V1**), Semantic (**V5**), GraphRAG	Д1, Д2	[ОТКЛОНИТЬ]	**V0/V5** разрушают границы пунктов (`п. 2.3.1`), лишая до 22 баллов за точное цитирование; **V1** даёт чанки по 18–26 тыс. символов (переполнение и шум).

3. Детальный разбор полезных идей (что берём в реализацию и почему)

3.1. Пятиуровневое дерево документа и стратегия чанкинга V3 (Parent-Child)

Оба документа (особенно Д2 в §3 и §5) справедливо отвергают плоскую нарезку текста и предлагают модель `file` → `unit` → `section` → `clause` → `item`.

- **Почему уровень `unit` критичен:** в файлах МФТИ один физический документ содержит несколько юридически разных сущностей. Например, `Приказ N 3699-1.docx` включает сам Приказ (24 пункта), Лист согласования и 4 Приложения (Регламент формирования бюджета, План-график, Таблицу ЦФО). В каждом приложении нумерация разделов и пунктов начинается заново с `1.`. Без выделения `unit_id` ссылка «п. 2.1» неоднозначна.
- **Почему именно V3 (Parent-Child):** индексация на уровне `clause` (пункт `2.3` вместе с его подпунктами `а, б, в`, если суммарная длина ≤ 1200 символов) обеспечивает снайперское попадание в конкретную норму (К1: 8 б., К2: 6 б.). При этом хранение ссылки `parent_id` на весь родительский `section` (и ссылок `prev_id`/`next_id`) позволяет на этапе сборки контекста перед LLM подтянуть соседние пункты раздела и выдать полный пошаговый план действий без пропусков (К3: 8 б.).
- **Синтетический `chunk_id` ≠ `clause_no`:** в `Приказ N 3065-1.docx` из-за опечатки авторов регламента дважды встречаются пункты `2.6` и `2.7` с разным текстом. Использование порядкового синтетического ключа (`3065-1::reg::s2::c08`) при сохранении оригинального `clause_no="2.6"` для цитирования предотвращает перезапись чанков в БД.

3.2. Детерминированное контекстное обогащение (`embed_text` ≠ `raw_text`)

В Qdrant сохраняется чистый `raw_text` (для цитирования и показа пользователю), а эмбеддинг и лемматизированный BM25 строятся по полю `embed_text`, снабжённому префиксом: `[Документ: Приказ № 3065-1 от 25.11.2021 (ред. приказа 1385-1) · Статус: действует · Единица: Регламент открытия ФЛС · Раздел 3: Порядок открытия ФЛС · Пункт 3.4 · Роли: Руководитель проекта, ПФО, Бухгалтерия]` + текст пункта. **Аргумент:** свыше 40% пунктов в регламентах МФТИ не содержат названия процедуры внутри самого абзаца (например: *«В течение 3 рабочих дней направляет карточку на согласование»*). Префикс связывает такие пункты с темой документа без платных вызовов LLM.

3.3. Специализированная обработка таблиц, Excel-форм и листов согласования

- **Отсечение зоны `approval`:** в 8 DOCX-приказах в конце документа расположены таблицы `ЛИСТ СОГЛАСОВАНИЯ` из `1С:ДО` с фамилиями проректоров и начальников управлений. Если их индексировать наравне с текстом, запрос *«кто согласует смету проекта?»* вернёт список подписантов самого приказа вместо ролей по процедуре. Разметка `zone="approval"` и исключение её из основного поиска решают проблему.
- **Forward-fill и нарезка XLSX/DOCX-таблиц:** в `Финансовая структура 2026` (525 строк) коды ЦФО 1-го и 2-го уровня объединены вертикально (`merged_cells`). При построчном чтении дочерние лаборатории теряют привязку к физтех-школе/институту. Протяжка значений сверху вниз (`ffill`) и упаковка по 10–15 строк одного подразделения с повтором шапки таблицы сохраняют табличный контекст.
- **Извлечение формул из бланков смет:** файлы `Приложение 1а/1б` и `новая смета 2019.xlsx` — это пустые шаблоны с 848 формулами. Нормативы накладных расходов (`=SUM(...)*0.2` для РЦНИ или `0.082`) и лимиты ФОТ зашиты прямо в формулы ячеек. Парсер должен генерировать текстовую карточку структуры бланка и коэффициентов из формул.

3.4. Гибридный поиск в Qdrant: `exact=True`, лемматизированный BM25 и глоссарий

- **Точный поиск (`exact=True`):** объём всего корпуса после чанкинга составляет ~750–900 чанков. На таком масштабе приближённый граф HNSW не даёт выигрыша в скорости, но может терять редкие точные совпадения при фильтрации. Полный перебор (`exact=True`) работает за единицы миллисекунд со 100% полнотой.
- **Клиентский Sparse BM25 с `pymorphy3` + словарь аббревиатур:** стандартный токенизатор без русской морфологии не связывает формы *«командирование»* / *«командировке»* / *«командированный»*. Кроме того, в регламентах есть разделы «Термины и сокращения» (`ФЛС`, `КФО`, `ЦФО`, `РИД`, `УИТ`, `ФЭУ`, `ОКР`). Автоматический сбор пар `аббревиатура` ↔ `расшифровка` при парсинге и двустороннее расширение текста перед BM25 позволяют находить документ как по аббревиатуре, так и по полному названию.

4. Аргументированный разбор ошибочных и вредных идей (что отклоняем)

4.1. Фактическая ошибка в `ответ_соннет.txt` о «недостающих регламентах» и числе сканов

В `ответ_соннет.txt` (раздел 1 и п. 2.2) утверждается, что в датасете якобы всего 3 скана, а *«Регламент поселения в общежитие, Регламент поиска и подбора персонала, Регламент эксплуатации ЦОД отсутствуют в датасете»*, и предлагается настроить систему на отказ по этим вопросам.

- **Почему это грубая ошибка:** в папке `данные/` лежат ровно 20 файлов, включая `Регламент поселения сотрудников.pdf` (скан, 3 стр.), `Регламент эксплуатации центра обработки данных МФТИ, Физтех.pdf` (скан, 5 стр.) и `Регламент поиска и подбора персонала.pdf` (текстовый PDF, 10 стр.). Автор Д1 пропустил 2 файла при обходе директории и не распознал сканы. Настройка отказа по этим темам

приведёт к потере баллов на прямых вопросах жюри.

- **Реальный нюанс с поселением, который нужно обрабатывать:** в файле `Регламент поселения сотрудников.pdf` действительно есть дефект сканирования — между стр. 1 и стр. 2 пропущены пункты `2.1--2.5` (текст перескакивает с заголовка раздела 2 сразу на `п. 2.6`). Вот об этой неполноте исходного скана система должна честно предупреждать пользователя!

4.2. Опасность жёсткого фильтра `status == active` (`status != утратил`) по умолчанию

Оба документа предлагают по умолчанию фильтровать неактуальные документы на этапе векторного поиска в Qdrant.

- **Почему это навредит на хакатоне:** Во-первых, критерии **К2 (10 б.)** и **К4 (3 б.)** требуют, чтобы система распознавала разные редакции и **явно показывала пользователю расхождения и изменения между версиями**. Если чанки приказа `460-1` (2017) отсечены жёстким фильтром до поиска, LLM даже не узнает о существовании старой редакции и не сможет объяснить, что бумажный порядок через ПФО заменён на электронный в `1С:ДО` приказом `3065-1` (2021). Во-вторых, изменяющие приказы часто не дублируют все приложения базового приказа: например, в `460-1` содержится 5 приложений (включая Перечень критических технологий и шаблоны распоряжений), а в `3065-1` — только обновлённый текст Регламента и Карточка проекта (Приложения 1 и 2). Жёсткий фильтр `status != superseded` удалит из базы действующие приложения базового приказа.
- **Правильное решение (Version-Aware Expansion):** искать по всем версиям (кроме зоны `approval`), применять мягкий бустинг к действующим редакциям на этапе реранкинга, а при попадании в выдачу чанка со связью `supersedes` / `superseded_by` автоматически подгружать парный пункт другой редакции и передавать оба в LLM с явной меткой версий.

4.3. Неприменимость голого `Tesseract OCR` как основного инструмента для 5 сканов

Оба автора предлагают использовать `pdf2image + Tesseract (rus+eng)`.

- **Почему это плохое решение:** (1) На целевой машине в `/usr/share/tessdata` вообще не установлен пакет `rus.traineddata`. (2) Как видно из самого файла `ответ_соннет.txt`, Tesseract даёт критический уровень шума на наших сканах (*«оборулования»*, *«ст 'уденческие мероприя Гия»*), из-за чего не срабатывают регулярные выражения для номеров пунктов и таблиц. (3) В `460-1` и `Приказ и регламент по ЭБ.pdf` номера и даты приказов вписаны **от руки** в штамп регистрации — Tesseract их не берёт. (4) В `Приказ и регламент по ЭБ.pdf` на стр. 5–6 таблицы классификации помещений **повёрнуты на 90° (альбомная ориентация внутри книжного скана)** — без детекции ориентации или мультимодального чтения таблица превращается в кашу символов.
- **Правильное решение:** использовать Vision-LLM (VLM OCR в Markdown с сохранением таблиц и чтением рукописных штампов) для 44 страниц сканов с **кэшированием результата на диск по `sha256(file)`** (чтобы при перезапуске контейнера индексация занимала < 2 сек), оставив связку `Docling / RapidOCR / Tesseract` только как офлайн-фоллбэк для новых файлов.

4.4. Отказ от двухэтапного поиска по «карточке документа» (`ответ_соннет.txt`, п. 3.2)

Автор Д1 предлагает сначала искать Top-2 документа по сгенерированным саммари («карточкам документов»), и только внутри них искать пункты.

- **Почему это антипаттерн для нашего корпуса:** во всём датасете всего 20 документов и $\sim$800 чанков. Двухэтапная фильтрация создаёт узкое горлышко: если вопрос требует синтеза нескольких документов (например, *«какие нормы суточных и как их заложить в смету на 2026 год?»* $\rightarrow$ нужны `Приказ 3699-1`, `Регламент о командировании`, `Приказ 794-1` и `Распоряжение 700`), отсечение на первом шаге потеряет половину источников и обрушит баллы по К3 и К4. Глобальный поиск по всем 800 чанкам с контекстным префиксом одновременно учитывает и тему документа, и текст конкретного пункта без потери полноты.

4.5. Отказ от дедупликации по хэшу файла (`sha256(file)`)

В `ответ_соннет.txt` (п. 1.2) предлагается удалять дубликаты файлов в `ingest.py` по хэшу файла.

- **Почему не сработает:** дублирующиеся приложения в датасете имеют **разный формат и бинарный состав**: `Приказ N 3614-1.docx` включает текст приказа + таблицу финструктуры в Word, а `Приложение к приказу...xlsx` — ту же таблицу в Excel. Аналогично, `Приказ N 3699-1.docx` содержит приказ + регламент + приложения, а файл `Приложения к приказу_ о формировании бюджетирования 2026г..docx` — только приложения. Их `sha256` различны. Вместо удаления файла нужно связывать их в реестре как `master_doc` $\leftrightarrow$ `standalone_appendix`, индексируя табличную структуру из XLSX (где сохранена иерархия ячеек), но указывая в метаданных оба источника для корректного цитирования.

5. Итоговая целевая архитектура пайплайна (Synthesis)

1. **Ingestion & Normalization:** Маршрутизатор по типу файла (`DOCX` через `body.iterchildren()` с очисткой слитых ячеек и отсечением `ЛИСТ СОГЛАСОВАНИЯ`; `PDF-text` через `PyMuPDF/pdfplumber` со склейкой переносов и очисткой сносок вида `8123` $\rightarrow$ `812`; `PDF-scan` через кэшированный `VLM-OCR` с поддержкой повёрнутых таблиц и рукописных штампов; `XLSX` через `openpyxl` с `forward-fill` объединённых ячеек и экстракцией формул смет).
2. **Document Registry & Version Graph:** Автоматический парсер шапки приказа (`doc_number`, `doc_date`, триггеры *«Во изменение приказа...»*, *«признать утратившим силу...»*) + верифицированный `registry_overrides.yaml` для 20 эталонных файлов.
3. **Hierarchical Chunker (V3 Parent-Child):** Разбиение на `unit` $\rightarrow$ `section` $\rightarrow$ `clause` $\rightarrow$ `item`. Векторизация на уровне `clause` (≤ 1200 симв.) и табличных групп (10–15 строк с шапкой) с детерминированным префиксом `[Документ · Статус · Раздел · Пункт · Роли]`.
4. **Hybrid Search + Reranking + Context Assembly:** Qdrant (`exact=True`): `Dense (BGE-M3)` + `Sparse BM25 (pymorphy3 + глоссарий аббревиатур)` $\rightarrow$ `RRF (top 30)` $\rightarrow$ `Cross-Encoder Reranker (BGE-reranker-v2-m3, top 8)`. Проверка порога отказа (`max_score` $< \tau$). Расширение контекста: подгрузка родительского `section`, соседних пунктов и связанных версий (`supersedes`/`superseded_by`) для явного отображения коллизий в ответе.